

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ – ĐẠI HỌC QUỐC GIA
HÀ NỘI
KHOA TRÍ TUỆ NHÂN TẠO

HỌC PHẦN: HỌC MÁY

BÁO CÁO BÀI TẬP LỚN
MACHINE LEARNING
HỆ THỐNG PHÂN LOẠI UNG THƯ VÚ DỰA
TRÊN DỮ LIỆU Y SINH

Giảng viên: Trần Hồng Việt

Thành viên nhóm:

Trần Quang Thái - MSSV: 24022451

Hà Ngọc Thiện - MSSV: 24022457

Lê Minh Chiến - MSSV: 24022271

Năm học 2026

Mục lục

1	ĐẶT VẤN ĐỀ	3
1.1	Giới thiệu bài toán ung thư vú	3
1.2	Tính cấp thiết trong ngữ cảnh y tế	3
1.3	Vai trò của Machine Learning	3
1.4	Mục tiêu đề tài	3
1.5	Phạm vi nghiên cứu	4
1.6	Đóng góp của đề tài	4
2	CƠ SỞ LÝ THUYẾT	5
2.1	Dữ liệu nghiên cứu	5
2.2	Các thuật toán học máy được áp dụng	5
2.3	Các độ đo đánh giá mô hình	8
2.4	Tầm quan trọng của Recall so với Accuracy trong phân loại ung thư . .	8
3	PHƯƠNG PHÁP ĐỀ XUẤT	10
3.1	Kiến trúc hệ thống và luồng công việc tổng thể	10
3.2	Nạp và kiểm định dữ liệu	11
3.3	Làm sạch dữ liệu và Xử lý ngoại lai	11
3.4	Xử lý đặc trưng và Phân tách dữ liệu	12
3.5	Huấn luyện mô hình, Stratified KFold và GridSearchCV	12
3.6	Đánh giá và Tối ưu hóa ngưỡng quyết định	13
3.7	Luật lựa chọn ưu tiên y tế	13
3.8	Giải thích mô hình	13
3.9	Triển khai ứng dụng giao diện Streamlit	14
4	THỰC NGHIỆM VÀ ĐÁNH GIÁ	15

4.1	Môi trường và thiết lập thực nghiệm	15
4.2	Đánh giá kiểm chứng chéo	15
4.3	Tinh chỉnh siêu tham số	16
4.4	So sánh các mô hình trên tập kiểm thử	16
4.5	Tối ưu hóa ngưỡng quyết định	17
4.6	Phân tích chi tiết mô hình tốt nhất	18
4.7	Giải thích mô hình	19
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	22
5.1	Kết luận và Kết quả đạt được	22
5.2	Hạn chế hiện tại	22
5.3	Hướng phát triển tương lai	23
	Phân công công việc	24
	Tài liệu tham khảo	25

CHƯƠNG 1. ĐẶT VẤN ĐỀ

1.1 Giới thiệu bài toán ung thư vú

Phân loại ung thư vú là một bài toán học máy phân loại nhị phân (binary classification) dựa trên dữ liệu y sinh dạng bảng. Đầu vào của bài toán là 30 thuộc tính số hóa mô tả các đặc trưng hình học và kết cấu của nhân tế bào khối u. Đầu ra của bài toán là nhãn dự đoán tình trạng khối u:

- **Lành tính** (Benign - được mã hóa là 0)
- **Ác tính** (Malignant - được mã hóa là 1)

1.2 Tính cấp thiết trong ngữ cảnh y tế

Lỗi âm tính giả (False Negative - dự đoán một khối u ác tính thành lành tính) là một lỗi vô cùng nguy hiểm. Việc bỏ sót ca ác tính có thể làm chậm trễ quá trình thăm khám chuyên khoa, xét nghiệm và điều trị, đe dọa trực tiếp tới tính mạng người bệnh. Do đó, việc xây dựng một hệ thống sàng lọc có khả năng hạn chế tối đa số ca âm tính giả là nhu cầu vô cùng cấp thiết.

1.3 Vai trò của Machine Learning

Machine Learning đóng vai trò như một công cụ hỗ trợ để phân tích nhanh chóng 30 đặc trưng tế bào phức tạp mà mắt thường hoặc các phương pháp thủ công khó tổng hợp. Tuy nhiên, hệ thống này chỉ phục vụ mục đích học tập và hỗ trợ tham khảo, không phải thiết bị y tế và tuyệt đối không thay thế bác sĩ, xét nghiệm lâm sàng hay các chẩn đoán y khoa chính thức.

1.4 Mục tiêu đề tài

Mục tiêu chính của đề tài là xây dựng một quy trình (pipeline) Machine Learning hoàn chỉnh bao gồm:

- Đọc tập dữ liệu, kiểm tra chất lượng dữ liệu, phát hiện nhiễu và ngoại lai.
- Tiền xử lý dữ liệu chặt chẽ nhằm tránh rò rỉ dữ liệu (data leakage).
- Huấn luyện 6 thuật toán Machine Learning cơ bản và đánh giá chúng dựa trên các thang đo y tế.
- Lựa chọn mô hình tốt nhất theo “quy tắc ưu tiên y tế”, tối ưu hóa ngưỡng quyết định (threshold).
- Cung cấp ứng dụng giao diện Streamlit cho phép dự đoán đơn lẻ và dự đoán hàng loạt (batch prediction).

1.5 Phạm vi nghiên cứu

Hệ thống nằm trong phạm vi của một bài tập lớn học thuật. Sản phẩm bao gồm quy trình huấn luyện ngoại tuyến (offline training), ứng dụng tương tác Streamlit, các mô hình đã được lưu trữ (artifacts) và báo cáo thực nghiệm. Hệ thống không nhằm tới việc tích hợp thực tế tại bệnh viện hay triển khai trên dữ liệu lâm sàng chưa được kiểm chứng.

1.6 Đóng góp của đề tài

Đề tài cung cấp một quy trình phân tích tự động, có đánh giá chặt chẽ, và xây dựng một quy tắc lựa chọn mô hình (Medical-First rule) ưu tiên Recall thay vì Accuracy. Bên cạnh đó, đề tài chú trọng tới việc giải thích mô hình (Model Explainability) thông qua chỉ số SHAP và độ quan trọng của đặc trưng (Feature Importance), giúp làm minh bạch các quyết định của hệ thống.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Dữ liệu nghiên cứu

Tập dữ liệu được sử dụng là *Breast Cancer Wisconsin Diagnostic dataset*. Tập dữ liệu này chứa 569 mẫu bệnh với tổng cộng 31 cột (bao gồm 30 đặc trưng đầu vào và 1 cột nhãn mục tiêu). Các thuộc tính là các thông số hình học như: bán kính trung bình (mean radius), độ mịn (mean smoothness), độ lồi lõm (mean concavity), và các sai số cũng như giá trị tồi tệ nhất (worst) tương ứng của chúng. Dữ liệu có chất lượng tốt, không có giá trị khuyết (missing values) và không có dòng trùng lặp (duplicate rows).

Bảng 2.1: Phân bố lớp trong tập dữ liệu

Lớp	Số lượng mẫu	Tỷ lệ (%)
Lành tính (Benign)	357	62,74
Ác tính (Malignant)	212	37,26
Tổng cộng	569	100,00

Lớp Benign chiếm 357 mẫu (62,74%) và lớp Malignant chiếm 212 mẫu (37,26%). Dữ liệu có sự chênh lệch nhẹ nhưng không bị mất cân bằng lớp ở mức độ nghiêm trọng (class imbalance detected: False). Sự phân bố này cho phép huấn luyện các thuật toán mà không bắt buộc dùng các kỹ thuật sinh thêm dữ liệu phức tạp. Tuy nhiên, nó vẫn đòi hỏi việc phân tách dữ liệu huấn luyện - kiểm thử phải sử dụng kỹ thuật phân tầng (Stratified) để đảm bảo duy trì cấu trúc của dữ liệu thực tế.

2.2 Các thuật toán học máy được áp dụng

- **Logistic Regression:** Học một biên phân tách tuyến tính trong không gian đặc trưng và sử dụng hàm sigmoid để ước lượng xác suất. Phương pháp này đơn giản, nhanh, nhưng rất nhạy cảm với thang đo của dữ liệu nên yêu cầu chuẩn hóa (StandardScaler).
- **Decision Tree:** Xây dựng các nhánh quyết định if-else dựa trên các đặc trưng để phân loại. Rất dễ giải thích bằng hình ảnh nhưng gặp nhược điểm là dễ bị

quá khớp (overfitting) với dữ liệu huấn luyện.

- **Random Forest:** Là mô hình kết hợp (ensemble) của nhiều cây quyết định, trong đó mỗi cây học trên một tập mẫu con và tập đặc trưng ngẫu nhiên. Thuật toán này rất mạnh trên dữ liệu dạng bảng, giảm quá khớp và cho phép mô hình hóa các quan hệ phi tuyến phức tạp.
- **Support Vector Machine (SVM):** Tìm siêu phẳng tối ưu giúp tối đa hóa khoảng cách (margin) giữa các lớp, sử dụng hàm nhân RBF linh hoạt để xử lý các phân tách phi tuyến.
- **K-Nearest Neighbors (KNN):** Gán nhãn cho một mẫu mới dựa trên nhãn của k mẫu gần nhất trong không gian. Phương pháp này đơn giản nhưng tính toán khá chậm trên tập dữ liệu lớn và dễ bị ảnh hưởng bởi nhiễu.
- **Naive Bayes (GaussianNB):** Áp dụng định lý Bayes với giả định các đặc trưng đầu vào độc lập với nhau và tuân theo phân phối chuẩn. Mặc dù giả định độc lập thường sai lệch với dữ liệu thực tế có tương quan, nhưng thuật toán lại cung cấp một baseline xác suất rất nhanh.

Bảng 2.2: So sánh ưu điểm và nhược điểm của các mô hình học máy

Mô hình	Ưu điểm	Nhược điểm
Logistic Regression	Đơn giản, tốc độ huấn luyện nhanh, dễ giải thích, cung cấp xác suất đầu ra rõ ràng làm cơ sở (baseline) tốt.	Bị giới hạn khi mô hình hóa các quan hệ phi tuyến phức tạp, rất nhạy cảm với thang đo của đặc trưng (cần StandardScaler).
Decision Tree	Rất dễ giải thích quy tắc ra quyết định, có thể trực quan hóa thành dạng cây, không yêu cầu chuẩn hóa dữ liệu.	Rất dễ bị quá khớp (overfitting) với dữ liệu huấn luyện, hiệu năng thường thấp hơn các mô hình kết hợp (ensemble).
Random Forest	Rất mạnh trên dữ liệu dạng bảng, giảm thiểu quá khớp so với cây đơn lẻ, mô hình hóa tốt các quan hệ phi tuyến, cung cấp được độ quan trọng của đặc trưng.	Mô hình dạng “hộp đen”, khó giải thích chi tiết hơn cây đơn lẻ, kích thước mô hình lớn hơn và dự đoán chậm hơn mô hình tuyến tính.
SVM	Hiệu quả cao với các tập dữ liệu vừa và nhỏ, sử dụng nhân RBF linh hoạt để tạo ra biên phân tách mạnh mẽ.	Đòi hỏi chuẩn hóa dữ liệu, thời gian huấn luyện tăng nhanh khi dữ liệu lớn, việc xuất xác suất cần thêm bước tính toán.
KNN	Thuật toán đơn giản, trực quan, không đưa ra giả định về phân bố dữ liệu.	Cần chuẩn hóa dữ liệu, tốc độ dự đoán chậm trên tập dữ liệu lớn, nhạy cảm với nhiễu và lựa chọn số láng giềng.
Naive Bayes	Tốc độ huấn luyện và dự đoán rất nhanh, tạo ra một baseline xác suất hiệu quả.	Giả định các đặc trưng độc lập với nhau, điều này thường không đúng với dữ liệu y sinh có tương quan cao, nên hiệu năng thường thấp hơn các mô hình ensemble.

Bảng 2.2 cho thấy mỗi thuật toán học máy đều có những ưu điểm và hạn chế riêng. Các mô hình đơn giản như Logistic Regression và Naive Bayes có ưu thế về tốc độ huấn luyện, khả năng giải thích và chi phí tính toán thấp. Ngược lại, các mô hình phức tạp hơn như Random Forest và SVM thường đạt hiệu năng dự đoán cao hơn nhờ khả năng học được các mối quan hệ phi tuyến trong dữ liệu, nhưng đánh đổi bằng việc khó diễn giải và yêu cầu tài nguyên tính toán lớn hơn.

Việc lựa chọn mô hình phù hợp không chỉ phụ thuộc vào độ chính xác mà còn phải cân nhắc giữa hiệu năng, khả năng giải thích và chi phí triển khai. Trong bối cảnh

bài toán phân loại ung thư vú, khả năng giải thích kết quả dự đoán là một yếu tố quan trọng bên cạnh hiệu suất phân loại. Do đó, đề tài tiến hành thực nghiệm trên nhiều nhóm thuật toán khác nhau, bao gồm mô hình tuyến tính, mô hình dựa trên cây quyết định, mô hình dựa trên khoảng cách và mô hình xác suất, nhằm đánh giá toàn diện và lựa chọn được mô hình phù hợp nhất theo các tiêu chí y tế đã đề ra.

2.3 Các độ đo đánh giá mô hình

Đề tài sử dụng nhiều độ đo để có góc nhìn toàn diện:

- **Accuracy:** Tỷ lệ các dự đoán đúng trên toàn bộ tập mẫu.
- **Precision (M):** Tỷ lệ các ca thực sự ác tính trong số những ca mô hình chẩn đoán là ác tính. Precision thấp sinh ra nhiều dương tính giả (FP), làm bệnh nhân lo lắng và gây lãng phí nguồn lực y tế.
- **Recall (M):** Tỷ lệ các ca được dự đoán đúng trong tổng số các bệnh nhân thực sự mắc ung thư ác tính.
- **F1-score (M):** Trọng số điều hòa giữa Precision và Recall, dùng để cân bằng và so sánh khi hai giá trị này ngược chiều nhau.
- **ROC-AUC:** Diện tích dưới đường cong ROC, đo lường khả năng xếp hạng phân biệt giữa hai lớp độc lập với một ngưỡng quyết định cụ thể.
- **PR-AUC:** Diện tích dưới đường cong Precision-Recall, rất hiệu quả khi đánh giá lớp thiểu số trong dữ liệu.
- **MCC (Matthews Correlation Coefficient):** Hệ số đo mức độ tương quan từ -1 đến 1 tính toán cân bằng trên cả TP, TN, FP, FN.
- **Confusion Matrix:** Ma trận nhầm lẫn cung cấp cái nhìn chi tiết về 4 kết quả: TN (Lành tính đoán đúng), FP (Lành tính đoán nhầm thành Ác tính), FN (Ác tính đoán nhầm thành Lành tính) và TP (Ác tính đoán đúng).


2.4 Tầm quan trọng của Recall so với Accuracy trong phân loại ung thư

Trong sàng lọc ung thư vú, mục tiêu cốt lõi là không được phép bỏ sót các bệnh nhân đang mang mầm bệnh. Chỉ số Recall (M) đo lường trực tiếp khả năng phát hiện

đúng các ca ác tính. Nếu chỉ tối ưu hóa Accuracy, mô hình có thể đạt điểm độ chính xác tổng thể rất cao nhờ đoán đúng phần lớn các ca lành tính, nhưng lại bỏ sót những ca Ác tính (False Negative). Một lỗi False Negative mang rủi ro lớn hơn rất nhiều so với False Positive, vì nó làm chậm quá trình chữa trị của bệnh nhân. Chính vì thế, Recall luôn được hệ thống thiết lập là tiêu chí đánh giá và lựa chọn mô hình quan trọng nhất.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Kiến trúc hệ thống và luồng công việc tổng thể



Hình 3.1: Sơ đồ luồng công việc tổng thể của hệ thống

Hệ thống phân loại ung thư vú được thiết kế theo kiến trúc mô-đun hóa (module-based architecture) nhằm tách biệt rõ ràng giữa phần giao diện (UI) và logic nghiệp vụ học máy (ML pipeline). Hệ thống không nhằm tới việc triển khai như một thiết bị

y tế chính thức mà hoạt động như một công cụ hỗ trợ và báo cáo học thuật. Luồng công việc tổng thể (End-to-End Workflow) bao gồm một quy trình toàn diện từ lúc nạp dữ liệu cho tới khi dự đoán, trải qua các bước: nạp dữ liệu, tiền xử lý, huấn luyện mô hình, đánh giá, tinh chỉnh siêu tham số, tối ưu hóa ngưỡng quyết định, giải thích mô hình và lưu trữ các tạo tác (artifacts) để tái sử dụng.

Đường ống (Pipeline) được thiết kế theo hướng tuyến tính một chiều và chặt chẽ. Đặc biệt, khâu kiểm chứng chéo (Cross Validation), tinh chỉnh siêu tham số (GridSearchCV) và tối ưu hóa ngưỡng (Threshold Optimization) được gói gọn hoàn toàn trong tập dữ liệu huấn luyện, tách biệt hoàn toàn với tập kiểm thử. Việc cấu trúc một sơ đồ chuẩn chỉnh như trên giúp giải quyết triệt để rủi ro rò rỉ dữ liệu (Data Leakage) - một lỗi rất phổ biến trong học máy. Sơ đồ này minh chứng cho tính nghiêm ngặt của phương pháp thực nghiệm: mô hình học máy được tinh chỉnh tối đa ở môi trường huấn luyện, nhưng năng lực thực sự của nó được định đoạt một cách công bằng và khách quan nhất tại các khâu đánh giá và giải thích ở phía cuối đường ống.

3.2 Nạp và kiểm định dữ liệu

Bước đầu tiên của quy trình là nạp dữ liệu từ tệp tin cơ sở định dạng CSV thông qua mô-đun xử lý dữ liệu. Quá trình kiểm định dữ liệu (Data Validation) được thực hiện một cách tự động và nghiêm ngặt. Hệ thống sẽ kiểm tra cấu trúc (schema), kiểu dữ liệu (dtypes), thống kê số lượng giá trị khuyết (missing values), các dòng trùng lặp (duplicate rows), các dải giá trị không hợp lệ (invalid ranges), ngoại lai (outliers) và hiện tượng mất cân bằng lớp (class imbalance). Toàn bộ quá trình kiểm định này sẽ tổng hợp thành một báo cáo chất lượng dữ liệu chi tiết, trong đó tập dữ liệu hiện tại đạt điểm chất lượng 85/100.

3.3 Làm sạch dữ liệu và Xử lý ngoại lai

Trong bước làm sạch dữ liệu, các giá trị chuỗi văn bản không chuẩn hoặc các ký hiệu thể hiện sự thiếu hụt dữ liệu (missing tokens) được chuyển đổi về định dạng rỗng (`pd.NA`) chuẩn của hệ thống. Các nhãn mục tiêu (target labels) được chuẩn hóa về định dạng nhị phân, loại bỏ các dòng bị khuyết nhãn mục tiêu vì chúng không thể sử dụng cho học có giám sát. Đặc biệt, để tránh hiện tượng rò rỉ dữ liệu giữa tập huấn luyện và tập kiểm thử, các dòng trùng lặp bị xóa bỏ ngay trước khi thực hiện phân tách dữ liệu.

Đối với xử lý ngoại lai (Outlier Detection), hệ thống sử dụng kết hợp 3 kỹ thuật:

Khoảng tứ phân vị (IQR), Điểm chuẩn (Z-score) và Rừng cô lập (IsolationForest). Tuy nhiên, quy tắc (policy) của hệ thống đối với các giá trị ngoại lai là “chỉ đánh dấu, không tự động xóa bỏ” (flag only, not remove). Quyết định này xuất phát từ đặc thù y tế: các giá trị ngoại lai có thể là những ca bệnh hiếm gặp nhưng hoàn toàn hợp lệ, việc tự động xóa bỏ có thể làm mất đi các tín hiệu lâm sàng quan trọng.

3.4 Xử lý đặc trưng và Phân tách dữ liệu

Dữ liệu được phân tách thành tập huấn luyện (Train set) và tập kiểm thử (Test set) theo tỷ lệ 80/20 (`test_size = 0.2`) với giá trị mầm ngẫu nhiên (`random_state`) là 42. Để đảm bảo cấu trúc phân bố của lớp Lành tính và Ác tính không bị biến đổi sau khi chia, kỹ thuật phân tầng (Stratified) dựa trên biến mục tiêu đã được áp dụng.

Biến mục tiêu (`diagnosis`) được mã hóa trong đó lớp Ác tính (Malignant) là lớp tích cực (positive class - mã hóa là 1) và Lành tính (Benign) là lớp tiêu cực (mã hóa là 0). Để đảm bảo không có sự rò rỉ dữ liệu trong quá trình tiền xử lý, các bộ chuẩn hóa thang đo (StandardScaler) không được áp dụng trên toàn bộ dữ liệu ngay từ đầu. Thay vào đó, chúng được đưa vào bên trong các đường ống (Pipeline) của từng mô hình cụ thể (chẳng hạn như Logistic Regression, SVM, KNN) và chỉ được học (`fit`) trên tập huấn luyện.

3.5 Huấn luyện mô hình, Stratified KFold và GridSearchCV

Hệ thống tiến hành huấn luyện đồng thời 6 thuật toán học máy cơ bản trên tập dữ liệu huấn luyện: Logistic Regression (kèm StandardScaler), Decision Tree, Random Forest, SVM (kèm StandardScaler), K-Nearest Neighbors (kèm StandardScaler) và Naive Bayes.

Để đánh giá tính ổn định của các mô hình mà không làm “ô nhiễm” (contaminate) tập kiểm thử (hold-out test set), hệ thống sử dụng phương pháp kiểm chứng chéo phân tầng 5 nếp gấp (5-Fold Stratified Cross-Validation) chỉ thực hiện trên tập huấn luyện. Quá trình tinh chỉnh siêu tham số (Hyperparameter Tuning) được thực hiện bằng kỹ thuật tìm kiếm dạng lưới (GridSearchCV) với 3 nếp gấp (3-fold CV). Quá trình này sử dụng thang đo Recall làm tiêu chí đánh giá tối ưu hóa (`scoring='recall'`) nhằm gia tăng khả năng bắt bệnh. Do giới hạn về thời gian chạy minh họa, không gian tìm kiếm (search grid) được thiết lập ở quy mô nhỏ.

3.6 Đánh giá và Tối ưu hóa ngưỡng quyết định

Mô hình được đánh giá toàn diện qua nhiều độ đo khác nhau trên tập kiểm thử. Bên cạnh đó, hệ thống thực hiện một bước Tối ưu hóa ngưỡng quyết định (Decision Threshold Optimization). Thông thường, các thuật toán phân loại nhị phân sử dụng ngưỡng 0,5 để quyết định nhãn. Tuy nhiên, ngưỡng này không phải lúc nào cũng tối ưu cho bài toán ưu tiên Recall. Thuật toán đã chạy thử nghiệm các ngưỡng quyết định từ 0,30 đến 0,60 với bước nhảy 0,05 (được tính toán riêng trên tập huấn luyện) để tìm ra điểm cân bằng tốt nhất, và ngưỡng 0,30 đã được lựa chọn làm ngưỡng chuẩn (decision_threshold) để lưu trữ và ứng dụng cho việc dự đoán.

3.7 Luật lựa chọn ưu tiên y tế

Thay vì lựa chọn mô hình tốt nhất dựa trên độ chính xác tổng thể (Accuracy) như các bài toán phân loại thông thường, đề tài này thiết lập và áp dụng một quy tắc lựa chọn ưu tiên y tế chặt chẽ nhằm giảm thiểu tối đa các ca âm tính giả (False Negative). Quy tắc lựa chọn mô hình tốt nhất tuân thủ thứ tự ưu tiên sau:

1. Chỉ số Recall của lớp Malignant (Ác tính) cao nhất.
2. Số ca False Negative (âm tính giả) thấp nhất.
3. Điểm F1-score của lớp Malignant cao nhất.
4. Diện tích dưới đường cong ROC (ROC-AUC) cao nhất.
5. Độ chính xác tổng thể (Accuracy) cao nhất.
6. Nếu các chỉ số trên ngang bằng, ưu tiên mô hình đơn giản và dễ giải thích hơn.

3.8 Giải thích mô hình

Để tránh việc các mô hình học máy trở thành “hộp đen” (black box) đối với người dùng, đặc biệt là trong môi trường liên quan đến y sinh, hệ thống tích hợp mô-đun giải thích mô hình. Tùy thuộc vào bản chất của mô hình được chọn, thuật toán SHAP (SHapley Additive exPlanations) với TreeExplainer (dành cho mô hình dạng cây) hoặc LinearExplainer (dành cho mô hình tuyến tính) sẽ được gọi để tính toán mức độ đóng góp của từng đặc trưng (feature) vào kết quả dự đoán cuối cùng. Bên cạnh đó, mức độ quan trọng tổng thể của các đặc trưng (Global Feature Importance)

cũng được trích xuất và lưu dưới dạng biểu đồ. Nếu thư viện SHAP gặp lỗi hoặc không khả dụng trong môi trường, hệ thống có cơ chế dự phòng an toàn (fallback) để đảm bảo không bị gián đoạn và vẫn hiển thị được các độ quan trọng đặc trưng cơ bản.

3.9 Triển khai ứng dụng giao diện Streamlit

Toàn bộ quy trình nạp dữ liệu, huấn luyện, đánh giá và giải thích mô hình được bọc (wrap) trong một giao diện tương tác (UI) xây dựng bằng thư viện Streamlit. Giao diện được cấu trúc thành 5 trang chính:

- **Trang Giới thiệu (Intro Page):** Cung cấp thông tin và cảnh báo y tế hệ thống.
- **Trang Khám phá Dữ liệu (Data Page):** Thực hiện phân tích dữ liệu khám phá (EDA), hiển thị phân bố nhãn, dữ liệu ngoại lai và bản đồ nhiệt tương quan (Correlation Heatmap).
- **Trang Huấn luyện (Training Page):** Cho phép người dùng chạy lại đường ống học máy (pipeline), xem lại lý do lựa chọn mô hình tốt nhất.
- **Trang Đánh giá (Evaluation Page):** Hiển thị chi tiết bảng so sánh, ma trận nhầm lẫn (Confusion Matrix), đường cong ROC và giải thích SHAP.
- **Trang Dự đoán (Prediction Page):** Hỗ trợ hai chế độ. Ở chế độ “Single Prediction”, người dùng có thể nhập 30 thông số bằng tay hoặc dùng các ca bệnh mẫu (demo patients) để thử nghiệm. Ở chế độ “Batch Prediction”, ứng dụng hỗ trợ nạp tệp Excel/CSV chứa nhiều ca bệnh cùng lúc, thực hiện quy trình kiểm định chất lượng (validate) trên lô dữ liệu này và xuất kết quả dự đoán ra tệp tin cho phép tải xuống.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 Môi trường và thiết lập thực nghiệm

Thực nghiệm được triển khai thông qua một đường ống học máy (pipeline) tự động sử dụng ngôn ngữ Python. Các thuật toán học máy được xây dựng và tối ưu thông qua thư viện Scikit-Learn. Giao diện người dùng được xây dựng bằng Streamlit. Dữ liệu đầu vào chứa 569 mẫu và 30 đặc trưng. Quá trình chia tập dữ liệu huấn luyện và kiểm thử sử dụng tỷ lệ 80/20 với mầm ngẫu nhiên (random state) là 42 và áp dụng kỹ thuật phân tầng (stratify) trên biến mục tiêu.

4.2 Đánh giá kiểm chứng chéo

Trước khi đánh giá trên tập kiểm thử (hold-out test), hệ thống thực hiện kiểm chứng chéo phân tầng 5 nếp gấp (5-Fold Stratified CV) trên tập huấn luyện nhằm kiểm tra độ ổn định của các mô hình.

Bảng 4.1: Kết quả kiểm chứng chéo 5 nếp gấp trên tập huấn luyện

Mô hình	Accuracy	Precision (M)	Recall (M)	F1-score (M)	ROC-AUC
Logistic Regression	0,9736	0,9771	0,9529	0,9640	0,9958
Decision Tree	0,9253	0,9153	0,8824	0,8979	0,9455
Random Forest	0,9582	0,9534	0,9353	0,9434	0,9875
SVM	0,9714	0,9769	0,9471	0,9610	0,9949
KNN	0,9692	0,9879	0,9294	0,9575	0,9860
Naive Bayes	0,9407	0,9402	0,9000	0,9185	0,9878

Ghi chú: Dữ liệu bảng trích xuất từ tệp `cross_validation_results.csv`. Ký hiệu (M) chỉ lớp Malignant.

Trong pha huấn luyện, mô hình Logistic Regression và SVM cho kết quả ổn định và điểm số rất cao trên hầu hết các thang đo, đặc biệt là Recall (M) (lần lượt đạt 0,9529 và 0,9471). Kết quả kiểm chứng chéo cho thấy dữ liệu có tính phân tách tuyến tính khá tốt, do đó các mô hình tuyến tính (Logistic Regression, SVM) hoạt động vô cùng hiệu quả. Mô hình Decision Tree cho thấy sự thiếu ổn định và hiệu suất thấp nhất (Recall chỉ đạt 0,8824) do đặc tính dễ bị quá khớp của cây quyết định đơn lẻ.

4.3 Tinh chỉnh siêu tham số

Quá trình tinh chỉnh siêu tham số được thực hiện bằng kỹ thuật tìm kiếm dạng lưới (GridSearchCV) với 3 nếp gấp (3-fold CV), trong đó thang đo được tối ưu hóa duy nhất là Recall (M) nhằm phục vụ mục tiêu y tế.

Bảng 4.2: Kết quả tinh chỉnh siêu tham số

Mô hình	Best CV Recall (M)	Siêu tham số tốt nhất
Logistic Regression	0,9647	<code>C = 0.1, class_weight = 'balanced'</code>
Decision Tree	0,8886	<code>max_depth = None, min_samples_leaf = 2, min_samples_split = 2</code>
Random Forest	0,9296	<code>class_weight = None, max_depth = None, n_estimators = 300</code>
SVM	0,9472	<code>C = 2.0, class_weight = 'balanced', gamma = 'scale'</code>
KNN	0,9295	<code>n_neighbors = 3, weights = 'uniform'</code>

Điểm Recall của đa số các mô hình đều được cải thiện hoặc duy trì ở mức cao sau khi tinh chỉnh. Các siêu tham số mang tính “cân bằng lớp” (`class_weight='balanced'`) thường xuyên được thuật toán lựa chọn. Việc ưu tiên tối ưu hóa theo Recall cho thấy hệ thống sẵn sàng đánh đổi một phần Precision để đảm bảo bắt được nhiều ca bệnh (Malignant) nhất có thể. Không gian tìm kiếm được thiết lập tương đối nhỏ gọn phù hợp với một dự án học thuật và đảm bảo tính khả thi về thời gian chạy minh họa.

4.4 So sánh các mô hình trên tập kiểm thử

Đây là bước đánh giá quyết định. Mô hình tốt nhất được chọn dựa trên dữ liệu chưa từng nhìn thấy trong quá trình huấn luyện (Test set gồm 20% dữ liệu).

Bảng 4.3: So sánh hiệu suất các mô hình trên tập kiểm thử

Mô hình	Accuracy	Precision (M)	Recall (M)	F1 (M)	ROC-AUC	TN	FP	FN	TP
Random Forest	0,9737	1,0000	0,9286	0,9630	0,9954	72	0	3	39
SVM	0,9737	1,0000	0,9286	0,9630	0,9947	72	0	3	39
Logistic Regression	0,9649	0,9750	0,9286	0,9512	0,9960	71	1	3	39
KNN	0,9561	0,9744	0,9048	0,9383	0,9825	71	1	4	38
Naive Bayes	0,9386	1,0000	0,8333	0,9091	0,9934	72	0	7	35
Decision Tree	0,9035	0,9189	0,8095	0,8608	0,9153	69	3	8	34

Random Forest và SVM đạt kết quả xuất sắc và hoàn toàn ngang bằng nhau trên 4 tiêu chí đầu tiên: Accuracy (0,9737), Precision (1,0000), Recall (0,9286) và số ca âm tính giả FN (3 ca). Dựa vào Luật lựa chọn ưu tiên y tế (Medical-First Selection Rule) đã đề ra ở Chương 3, cả Random Forest, SVM và Logistic Regression đều đạt mức Recall (M) cao nhất là 0,9286 và mức FN thấp nhất là 3. Xét tới mức độ ưu tiên 3 (F1-score), Logistic Regression bị loại do F1 thấp hơn (0,9512 so với 0,9630). Trong giao đấu giữa Random Forest và SVM, Random Forest chiến thắng ở mức độ ưu tiên 4 nhờ có chỉ số ROC-AUC nhỉnh hơn (0,9954 so với 0,9947). Do đó, Random Forest được hệ thống tự động chỉ định là Mô hình tốt nhất (Best Model).


4.5 Tối ưu hóa ngưỡng quyết định

Ngưỡng quyết định mặc định của học máy là 0,5. Hệ thống đã tiến hành tính toán trên tập huấn luyện với các ngưỡng từ 0,30 đến 0,60.

Bảng 4.4: Tối ưu hóa ngưỡng quyết định cho lớp Malignant

Ngưỡng	Accuracy	Precision	Recall (M)	F1-score	ROC-AUC	TN	FP	FN	TP
0,3000	0,9912	0,9770	1,0000	0,9884	0,9999	281	4	0	170
0,4000	0,9934	0,9941	0,9882	0,9912	0,9999	284	1	2	168
0,5000	0,9934	1,0000	0,9824	0,9911	0,9999	285	0	3	167
0,6000	0,9912	1,0000	0,9765	0,9881	0,9999	285	0	4	166


Khi hạ ngưỡng quyết định từ 0,50 xuống 0,30, mô hình đạt được Recall tuyệt đối (1,0000) và hạ số ca âm tính giả (FN) xuống 0 trên tập huấn luyện. Đổi lại, số ca dương tính giả (FP) tăng nhẹ từ 0 lên 4. Bảng số liệu minh chứng rõ ràng cho sự đánh đổi (trade-off) trong phân loại. Bằng cách hạ ngưỡng xuống 0,30, hệ thống trở nên nhạy cảm hơn với các ca có dấu hiệu ác tính. Dù làm tăng tỷ lệ cảnh báo nhầm (False Positive), nhưng trong sàng lọc ung thư, điều này là hoàn toàn chấp nhận được để đổi lấy việc không bỏ sót bất cứ ca bệnh nào (False Negative = 0). Ngưỡng 0,30 đã được xuất thành tệp (`decision_threshold.joblib`) để ứng dụng thực tế.



Hình 4.1: Biểu đồ tối ưu hóa ngưỡng quyết định - sự biến thiên của Precision, Recall, F1-score khi thay đổi ngưỡng từ 0,30 đến 0,60


Đường biểu diễn Recall (M) đạt cực đại tại khu vực ngưỡng 0,30-0,35. Biểu đồ củng cố thêm tính đúng đắn của việc thiết lập ngưỡng dự đoán ở mức 0,30, tối đa hóa khả năng bắt bệnh ác tính.

4.6 Phân tích chi tiết mô hình tốt nhất



Hình 4.2: Ma trận nhầm lẫn của mô hình Random Forest trên tập kiểm thử (72 TN, 0 FP, 3 FN, 39 TP)

Mô hình đoán đúng 100% các ca lành tính (Specificity = 1,0, không có FP) nhưng vẫn để lọt 3 ca ác tính dự đoán nhầm thành lành tính (FN = 3). Mặc dù Random Forest là mô hình tốt nhất, con số 3 ca FN vẫn cho thấy mô hình không hoàn hảo tuyệt đối trên tập kiểm thử (đánh giá ở ngưỡng mặc định). Điều này nhắc nhở lý do vì sao dự án có cảnh báo: hệ thống chỉ mang tính tham khảo học thuật và không thay thế phán đoán của bác sĩ lâm sàng.




Hình 4.3: Đường cong ROC so sánh 6 mô hình trên tập kiểm thử

Đa số các đường cong đều bám sát góc trên cùng bên trái. AUC của Logistic Regression là 0,9960, Random Forest là 0,9954 và SVM là 0,9947. Decision Tree tụt hậu ở mức 0,9153. AUC tiệm cận 1 cho thấy khả năng phân tách độc lập với ngưỡng quyết định của phần lớn các thuật toán là cực kỳ xuất sắc. Nó chứng tỏ các đặc trưng hình học của nhân tế bào cung cấp tín hiệu sinh học rất mạnh mẽ để phân biệt tính chất khối u.


4.7 Giải thích mô hình

Để phá vỡ tính “hộp đen”, mức độ đóng góp của từng đặc trưng đã được tính toán.



Hình 4.4: Độ quan trọng của các đặc trưng - góc nhìn toàn cục (Global Feature Importance) theo mô hình Random Forest

Năm đặc trưng quan trọng nhất định hình quyết định của mô hình lần lượt là: *worst perimeter* (0,1475), *worst area* (0,1436), *worst concave points* (0,1156), *mean concave points* (0,0885) và *worst radius* (0,0869). Về mặt hình học sinh học, các đặc trưng biểu thị kích thước ở tình trạng xấu nhất (*worst perimeter*, *worst area*, *worst radius*) và số lượng điểm lõm trên chu vi tế bào (*concave points*) là những thông số mang tính quyết định nhất để dự đoán một khối u ác tính.



Hình 4.5: Phân tích SHAP Summary - mỗi chấm đại diện cho một mẫu dữ liệu; màu đỏ biểu thị giá trị đặc trưng cao, màu xanh biểu thị giá trị thấp; trục hoành thể hiện tác động tới quyết định dự đoán

Các chấm màu đỏ (giá trị cao) của nhóm thuộc tính *worst area*, *worst perimeter*, *worst concave points* đều nằm lệch mạnh về phía bên phải của mốc 0. Kết quả phân tích SHAP cực kỳ đồng nhất với Feature Importance. Nó trực tiếp chỉ ra quy luật: Kích thước tế bào càng lớn và độ lõm càng nhiều (chấm đỏ), giá trị SHAP dương càng cao, đồng nghĩa với việc mô hình càng bị thuyết phục đẩy kết quả dự đoán về lớp Ác tính (Malignant).

CHƯƠNG 5. KẾT LUẬN VÀ HƯỞNG PHÁT TRIỂN

5.1 Kết luận và Kết quả đạt được

Đề tài đã hoàn thành xuất sắc mục tiêu xây dựng một quy trình học máy hoàn chỉnh từ đầu đến cuối (end-to-end pipeline) cho bài toán phân loại ung thư vú. Kết quả đạt được bao gồm:

- Xây dựng thành công ứng dụng tương tác Streamlit hỗ trợ cả đánh giá trực quan (EDA), dự đoán đơn lẻ và dự đoán hàng loạt (Batch Prediction) thông qua tệp Excel/CSV.
- Thiết lập quy trình kiểm định chất lượng dữ liệu khắt khe, xác định không có giá trị khuyết và ghi nhận 172 dòng có dấu hiệu ngoại lai nhưng được giữ lại phục vụ tính toán vẹn lâm sàng.
- Huấn luyện và đánh giá 6 thuật toán học máy bằng phương pháp kiểm chứng chéo và tập kiểm thử độc lập.
- Thiết lập Luật ưu tiên y tế (Medical-First rule) và chọn Random Forest làm mô hình tốt nhất với điểm Recall đạt 0,9286, vượt qua tiêu chí Accuracy thuần túy.
- Tối ưu hóa ngưỡng quyết định chẩn đoán xuống mức 0,30 để đưa rủi ro âm tính giả (False Negative) trên tập huấn luyện về 0.

5.2 Hạn chế hiện tại

- Đề tài chỉ sử dụng dữ liệu mở có kích thước nhỏ (569 mẫu), không phản ánh toàn diện quần thể bệnh nhân thực tế.
- Quá trình tinh chỉnh siêu tham số (GridSearchCV) được cấu hình ở không gian tìm kiếm nhỏ nhằm đáp ứng thời gian chạy báo cáo, chưa khai thác hết giới hạn của mô hình.
- Hệ thống thiếu cơ chế kiểm chứng chéo lồng nhau (Nested Cross-Validation) để đánh giá các mô hình đã được tinh chỉnh một cách độc lập tuyệt đối.

- Ứng dụng cung cấp các cảnh báo cho dữ liệu y khoa bất thường (unusual values) nhưng hệ thống này tuyệt đối không phải là một thiết bị y tế và không đủ tiêu chuẩn để dùng làm chẩn đoán lâm sàng.

5.3 Hướng phát triển tương lai

- Áp dụng phương pháp Nested Cross-Validation (5 nếp gấp) để đánh giá mô hình chặt chẽ hơn, kết hợp với không gian tìm kiếm RandomizedSearchCV lớn hơn cho khâu tối ưu hóa.
- Tích hợp thêm biểu đồ giải thích SHAP/LIME chi tiết cho từng bệnh nhân ngay trong giao diện trang Dự đoán (Prediction Page) của ứng dụng Streamlit.
- Đánh giá khả năng của mô hình trên các tập dữ liệu ngoại kiểm (external validation) đến từ các bệnh viện thực tế để đo lường độ trượt dữ liệu (data drift).
- Tích hợp các công cụ quản lý vòng đời học máy như MLflow hoặc DVC để theo dõi và lưu trữ phiên bản của mô hình và dữ liệu trong dài hạn.

PHÂN CÔNG CÔNG VIỆC

Bảng 5.1: Phân công công việc nhóm

Thành viên	Khối lượng (%)	Chi tiết công việc thực hiện theo Pipeline
Lê Minh Chiến	33,3%	Nghiên cứu cơ sở lý thuyết về học máy và các thuật toán phân loại. Xây dựng module nạp dữ liệu, kiểm tra chất lượng dữ liệu, làm sạch dữ liệu và xử lý giá trị ngoại lai (Data Validation & Cleaning). Thực hiện phân tích dữ liệu khám phá (EDA) và chuẩn bị dữ liệu ban đầu. Viết Chương 1: Giới thiệu đề tài và Chương 2: Cơ sở lý thuyết.
Trần Quang Thái	33,3%	Thực hiện tiền xử lý dữ liệu và đặc trưng, chuẩn hóa dữ liệu và chia tập huấn luyện/kiểm tra. Cài đặt quy trình huấn luyện cho 6 mô hình: Logistic Regression, Decision Tree, Random Forest, SVM, KNN và Naive Bayes. Thực hiện GridSearchCV và Cross Validation để tối ưu siêu tham số. Xây dựng luật ưu tiên y tế (Medical Priority Rule) và tối ưu ngưỡng quyết định (Threshold Optimization). Viết Chương 3: Phương pháp nghiên cứu và xây dựng mô hình.
Hà Ngọc Thiện	33,3%	Xây dựng module đánh giá mô hình (Evaluation Module). Sinh các biểu đồ đánh giá như ROC Curve, Confusion Matrix và các chỉ số hiệu năng. Thực hiện giải thích mô hình bằng SHAP và phân tích Feature Importance. Xây dựng giao diện ứng dụng bằng Streamlit hỗ trợ dự đoán đơn lẻ (Single Prediction) và dự đoán hàng loạt (Batch Prediction). Viết Chương 4: Kết quả thực nghiệm và Chương 5: Kết luận và hướng phát triển.

TÀI LIỆU THAM KHẢO

1. Trần Hồng Việt (2026). *Bài giảng học phần Học máy (Machine Learning)*. Khoa Trí tuệ Nhân tạo, Trường Đại học Công nghệ - Đại học Quốc gia Hà Nội.
2. Vũ Hữu Tiệp (2018). *Machine Learning cơ bản*. Nhà xuất bản Khoa học và Kỹ thuật. (Tài liệu nền tảng phục vụ việc cài đặt và phân tích ưu/nhược điểm của 6 thuật toán: Logistic Regression, KNN, Naive Bayes, Decision Tree, Random Forest và SVM.)
3. Nguyễn Thanh Thủy (Chủ biên), Lê Tiến Định, Nguyễn Thị Thu Trang (2014). *Giáo trình Trí tuệ Nhân tạo*. Nhà xuất bản Bách khoa Hà Nội. (Cơ sở lý thuyết về không gian đặc trưng và các mô hình phân loại dữ liệu.)
4. Đỗ Văn Tiến (2021). Ứng dụng các mô hình học máy trong phân loại và dự đoán dữ liệu y sinh dạng bảng. *Tạp chí Nghiên cứu Khoa học và Công nghệ*. (Tài liệu tham khảo về tư duy ưu tiên Recall và xử lý ma trận nhầm lẫn trong bài toán y tế.)
5. Wolberg, W. H., Street, W. N., & Mangasarian, O. L. (1995). *Breast Cancer Wisconsin (Diagnostic) Data Set*. UCI Machine Learning Repository. <https://doi.org/10.24432/C5DW2B>.
6. Pedregosa, F., Varoquaux, G., Gramfort, A., *et al.* (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
7. Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). *Advances in Neural Information Processing Systems* 30.